

# 短视频五张表核心维度规整报告

报告日期：2026-04-15

分析基准：短视频数据汇总表\_20260121\_V2.xlsx

参考报告：鞋服电商短视频报告.pdf

运行模式：实时 DLC 拉数；优先命中结果表，未命中时降级到源表或跨表验证。

## 一、结论摘要

这次报告不再依据静态规划稿推断，而是直接对实时数仓做探测。最终结果表明，表 01、表 03 已能作为内容分析底座；表 02 语义层是否稳定落地要看结果表是否命中；表 04 仍是最关键的结构性缺口；表 05 可能退回源表验证，说明内容效果闭环尚未完全模型化。

从“用什么内容”的角度，真正可复用的标准层应该拆成资源形态维、商品语义维、平台表达维、关系归因维、效果反馈维。当前最优先补的不是再加更多标签，而是桥接关系与统一标准值。

## 二、参考前提

- 参考报告将鞋服短视频链路抽象为 5C：Content、Channel、Crowd、Commodity、Conversion。
- “用什么内容”不是单字段问题，而是从文件物理形态、商品语义、平台表达一直延伸到效果回流的连续结构。
- file\_id 与 platform\_source\_id 天然是一对多；若没有桥接层，内容归因一定失真。
- AI 标签适合补高语义字段，不适合代替实体映射和基础元数据治理。

## 三、实时探测总览

| 表                   | 规划目标                            | 实际使用                                    | 模式               | 总量      | 关键判断                                               |
|---------------------|---------------------------------|-----------------------------------------|------------------|---------|----------------------------------------------------|
| 01、【文件id】资源表        | dwd_t_file_resource_id          | data_dwd.dwd_t_file_resource_id         | result           | 6480876 | file_id 非唯一，当前总行数 6480876，去重后 6428578，底座实体仍存在重复污染。 |
| 02、【SPU、文件id】标签表    | dwd_file_label_id_spu           | data_dwd.dwd_file_label_id_spu          | result           | 6480876 | 品名 缺失率 75.12%，商品语义层目前还不适合直接作为稳定内容切片。               |
| 03、【平台素材id、SPU】标签表  | dwd_platform_source_label       | data_dwd.dwd_platform_source_label      | result           | 4119    | 内容大标签 缺失率 74.65%，平台表达层仍明显依赖补录或标题解析。                |
| 04、123的关联表          | dwd_file_platform_source_bridge | 未发现桥接结果表                                | cross_validation | NA      | 实时探测未发现桥接结果表，表 04 仍是数仓当前最关键的结构性缺口。                 |
| 05、【平台素材id，日期】数据指标表 | dwd_platform_source_metric_di   | data_dwd.dwd_short_video_analysis_incre | result           | 7951976 | 已完成实时探测                                            |

四、逐表分析

01 01、【文件id】资源表

规划目标表：dwd\_t\_file\_resource\_id；实际使用：data\_dwd.dwd\_t\_file\_resource\_id；模式：result

粒度：文件id；核心标签：平台、品牌、SPU、创作日期、是否已发、视频时长类型、视频宽幅度、图片大小、是否穿搭、是否白底图、是否主图

总行数：6480876；粒度去重数：6428578

| 时间字段         | 最早值                 | 最新值                 |
|--------------|---------------------|---------------------|
| create_time  | 2012-07-02 09:52:14 | 2026-04-14 19:04:18 |
| publish_date | 2023-02-02          | 5419-10-10          |

| 分布字段值 | 行数      |
|-------|---------|
| 图片    | 6402925 |
| 视频    | 77951   |

| 核心标签       | 来源字段/表达式                                                      | 填充数      | 缺失数    | 缺失率   | Top 分布                                                |
|------------|---------------------------------------------------------------|----------|--------|-------|-------------------------------------------------------|
| 平台         | platform                                                      | 5989660  | 491216 | 7.58% | 天猫:3906757；唯品会:1362812；抖音:401548；拼多多:123524；快手:121122 |
| 品牌         | brand                                                         | 6475451  | 5425   | 0.08% | 李宁:6339103；斯凯奇:136348                                 |
| SPU        | spu                                                           | 6470469  | 10407  | 0.16% | —                                                     |
| 创作日期       | create_time                                                   | 6480876  | NA     | 0.00% | —                                                     |
| 是否已发       | ods_t_file_informati<br>on.publish_date 推<br>导（仅视频源表）         | 86187    | NA     | 0.00% | 已发:74658；未发:11529                                     |
| 视频时长类<br>型 | ods_t_file_informati<br>on.video_duration_t<br>ype（仅视频源表<br>） | 86187    | NA     | 0.00% | 短视频:85247；中视频:826；长视频:114                             |
| 视频宽幅度      | ods_t_file_informati<br>on.width,height（仅<br>视频源表）            | 86187    | NA     | 0.00% | 竖屏:75356；方图:7343；横屏:3488                              |
| 图片大小       | ods_pic_for_up_ne<br>w_backup.length（<br>仅图片源表）               | 10697906 | NA     | 0.00% | —                                                     |
| 是否穿搭       | ods_t_image_file_inf<br>ormation.file_type（<br>仅图片源表）         | 644      | NA     | 0.00% | 否:366；是穿搭图:278                                        |
| 是否白底图      | ods_pic_for_up_ne<br>w_backup.content_t<br>ype（仅图片源表<br>）     | 10697906 | NA     | 0.00% | 否:7095358；是白底图:3602548                                |

| 核心标签 | 来源字段/表达式                                    | 填充数      | 缺失数 | 缺失率   | Top 分布              |
|------|---------------------------------------------|----------|-----|-------|---------------------|
| 是否主图 | ods_pic_for_up_new_backup.image_name（仅图片源表） | 10697900 | 6   | 0.00% | 否:10696257；是主图:1643 |

|                  |                                       |                  |  |  |  |
|------------------|---------------------------------------|------------------|--|--|--|
| runtime_note     | 表 01 是内容资源底座，重点看资源形态字段是否可稳定支撑“用什么内容”。 |                  |  |  |  |
| file_id_distinct | 6428578                               | 与总行数对比判断资源实体是否唯一 |  |  |  |

- file\_id 非唯一，当前总行数 6480876，去重后 6428578，底座实体仍存在重复污染。

## 02 02、【SPU、文件id】标签表

规划目标表：dwd\_file\_label\_id\_spu；实际使用：data\_dwd.dwd\_file\_label\_id\_spu；模式：result

粒度：SPU、文件id；核心标签：品名、统一大类、统一中类、统一赛道、性别、场景、风格

总行数：6480876；粒度去重数：55797

| 核心标签 | 来源字段/表达式                      | 填充数     | 缺失数     | 缺失率    | Top 分布                                                    |
|------|-------------------------------|---------|---------|--------|-----------------------------------------------------------|
| 品名   | product_name                  | 1612647 | 4868229 | 75.12% | —                                                         |
| 统一大类 | brand_big_cate/big_cate       | 6191828 | 289048  | 4.46%  | 服装:3506001；鞋:1982145；配件:584209；器材:76055；服饰:41285          |
| 统一中类 | mid_cate                      | 6143171 | 337705  | 5.21%  | T恤类:794262；卫衣类:632763；运动生活鞋类:492100；童鞋类:476035；卫裤类:434650 |
| 统一赛道 | sub_track                     | 6480876 | NA      | 0.00%  | 其他:4255098；短袖T恤:249953；夹克外套:202717；运动长裤:197690；卫衣:136610  |
| 性别   | gender_lining_bi/gender       | 6480876 | NA      | 0.00%  | 男性:2500096；女性:1219355；中性:1081642；无:919972；童:759811        |
| 场景   | scene_tb16/scene_rpa_material | 6480876 | NA      | 0.00%  | 其它:6253803；慢跑:111148；竞训:64829；健步:37277；越野跑:8567           |
| 风格   | style_tb16/style_rpa_material | 6480876 | NA      | 0.00%  | 其它:4338239；运动:1085530；时尚:768362；休闲:211180；户外:74873        |

|              |                                  |               |  |  |  |
|--------------|----------------------------------|---------------|--|--|--|
| runtime_note | 表 02 是商品语义层，重点看内容是否能稳定挂到商品与场景风格。 |               |  |  |  |
| distinct_spu | 55797                            | SPU 是语义层的天然主键 |  |  |  |

- 品名 缺失率 75.12%，商品语义层目前还不适合直接作为稳定内容切片。

03 03、【平台素材id、SPU】标签表

规划目标表：dwd\_platform\_source\_label；实际使用：data\_dwd.dwd\_platform\_source\_label；模式：result

粒度：平台素材id、SPU；核心标签：发布日期、发布作者、内容大标签

总行数：4119；粒度去重数：3980

| 时间字段         | 最早值        | 最新值        |
|--------------|------------|------------|
| publish_date | 2023-02-12 | 2026-04-09 |

| 分布字段值 | 行数   |
|-------|------|
| 得物    | 2230 |
| 抖音    | 1004 |
| 天猫    | 885  |

| 核心标签  | 来源字段/表达式     | 填充数  | 缺失数  | 缺失率    | Top 分布                                   |
|-------|--------------|------|------|--------|------------------------------------------|
| 发布日期  | publish_date | 4119 | NA   | 0.00%  | —                                        |
| 发布作者  | author       | 4119 | NA   | 0.00%  | —                                        |
| 内容大标签 | big_tag      | 1044 | 3075 | 74.65% | 导购:602；种草:335；产品:98；测评:8；品宣:1            |
| 内容中标签 | middle_tag   | 1045 | 3074 | 74.63% | -:879；静物展示:64；上脚展示:29；口播讲解:25；Ai原创&二创:17 |

|                             |                                       |                |
|-----------------------------|---------------------------------------|----------------|
| runtime_note                | 表 03 是平台表达层，重点看平台标签是否真实可用，而不是停留在规划字段。 |                |
| distinct_platform_source_id | 3980                                  | 用于判断平台素材实体是否唯一 |

- 内容大标签 缺失率 74.65%，平台表达层仍明显依赖补录或标题解析。
- 内容中标签 缺失率 74.63%，平台表达层仍明显依赖补录或标题解析。

04 04、123的关联表

规划目标表：dwd\_file\_platform\_source\_bridge；实际使用：未发现桥接结果表；模式：cross\_validation

粒度：待定义；核心标签：file\_id、platform\_source\_id、SPU、SKU、映射规则、映射置信度、权重因子

| metric            | value   | comment       |
|-------------------|---------|---------------|
| t01_total_rows    | 6480876 | 资源底座总量        |
| t01_rows_with_spu | 6470469 | 资源底座中可挂商品的记录数 |
| t03_total_rows    | 4119    | 平台表达层总量       |

| metric            | value | comment              |
|-------------------|-------|----------------------|
| t03_rows_with_spu | 4116  | 平台表达层中可挂商品的记录数       |
| spu_overlap       | 1680  | 01 与 03 通过 SPU 的交集能力 |

- 实时探测未发现桥接结果表，表 04 仍是数仓当前最关键的结构性缺口。
- 当前只能通过 SPU 做弱关联验证，无法证明平台视频与原始素材是一一对应还是裁剪复用。

05 05、【平台素材id，日期】数据指标表

规划目标表：dwd\_platform\_source\_metric\_di；实际使用：data\_dwd.dwd\_short\_video\_analysis\_incre；模式：result

粒度：平台素材id，日期；核心标签：平台、点击量、曝光量

总行数：7951976；粒度去重数：NA

| 分布字段值 | 行数      |
|-------|---------|
| 抖音    | 3738186 |
| 得物    | 3192292 |
| 淘宝    | 1021498 |

| 核心标签 | 来源字段/表达式     | 填充数     | 缺失数     | 缺失率    | Top 分布                           |
|------|--------------|---------|---------|--------|----------------------------------|
| 平台   | platform     | 7951976 | NA      | 0.00%  | 抖音:3738186；得物:3192292；淘宝:1021498 |
| 点击量  | view_vol     | 1021487 | 6930489 | 87.15% | —                                |
| 曝光量  | exposure_vol | 4943497 | 3008479 | 37.83% | —                                |

|              |                                              |  |
|--------------|----------------------------------------------|--|
| runtime_note | 表 05 是效果反馈层，重点看指标表是否已落地；若未落地，则至少要验证源表能否形成闭环。 |  |
|--------------|----------------------------------------------|--|

## 五、关键风险

| 表                       | 字段/主题 | 风险判断                          |
|-------------------------|-------|-------------------------------|
| 02、【SPU、文件id】<br>标签表    | 品名    | 缺失率 75.12%，适合作为辅标签，不适合作为强主标签。 |
| 03、【平台素材id、S<br>PU】标签表  | 内容大标签 | 缺失率 74.65%，适合作为辅标签，不适合作为强主标签。 |
| 03、【平台素材id、S<br>PU】标签表  | 内容中标签 | 缺失率 74.63%，适合作为辅标签，不适合作为强主标签。 |
| 04、123的关联表              | 结果表状态 | 未命中结果表，说明这一层模型尚未稳定落地。         |
| 05、【平台素材id，<br>日期】数据指标表 | 点击量   | 缺失率 87.15%，不适合作为全量统一切片字段。     |

## 六、最终判断

- 表 01 可以作为资源底座，但高缺失字段不能直接冒充全量标准标签。
- 表 02 的价值在于把内容挂到商品语义；若结果表未稳定，则说明“用什么内容”的语义层仍在建设中。
- 表 03 是平台表达层，可直接观察大标签/中标签的真实可用性。
- 表 04 若不存在，就意味着当前所有 ROI 与复用分析都只能做弱关联。
- 表 05 即便有源表，也不等于闭环完成；必须与标准标签和桥接层连通才有经营价值。